

**Universidade do Minho**

Escola de Engenharia

Departamento de Informática

# **Conhecimento e Raciocínio não simbólico**


**Cesar Analide, Paulo Novais**

## Inteligência Artificial

- *“Every aspect of learning or any other feature of intelligence can in principle be so precisely described that a machine can be made to simulate it.*

*An attempt will be made to find how to make machines use language, form abstractions and concepts, solve kinds of problems now reserved for humans, and improve themselves.”*

John McCarthy, Dartmouth Conference, 1956



- Cada aspeto da aprendizagem ou qualquer outra característica da inteligência pode, em princípio, ser descrito de forma tão precisa que será possível construir uma máquina para o simular.  
Serão feitas tentativas para descobrir como fazer com que as máquinas usem a linguagem, formem abstrações e conceitos, resolvam tipos de problemas até agora reservados para os humanos, e sejam capazes de se melhorarem a si próprias.

## Inteligência Artificial

- A abordagem da Inteligência Artificial à representação de conhecimento expõe-se através de dois paradigmas:
  - Simbólico
    - Baseia-se na lógica para representar conhecimento;
    - Fundamenta o raciocínio na construção de sistemas de inferência;
  - Não simbólico, ou conexionista
    - Baseia o funcionamento do sistema na capacidade de aprender, generalizando;
    - Resolve problemas com base em conhecimento passado ou dados sobre a resolução de outros problemas;



## Inteligência Artificial

# Contextualização

### ■ Vantagens da abordagem simbólica:

- O problema da representação de conhecimento é simples;
- Grande poder expressivo das linguagens de representação;
- Mecanismos de inferência solidificados;

### ■ Vantagens da abordagem não simbólica:

- Capacidade de aprender a resolver problemas;
- Capacidade de generalizar a resolução de problemas;
- Tolerante a falhas.

## Soft Computing vs Hard Computing

- Soft Computing
  - Computational Intelligence / Inteligência Computacional;
  - Natural Computing / Computação Natural;
- O modelo subjacente a “Soft Computing” é a mente humana;
- “Soft Computing” difere de “Hard Computing” no sentido em que é tolerante à imprecisão, à incerteza, à verdade parcial e à aproximação, explorando estas capacidades para alcançar, por estes meios, a exequibilidade e a robustez de soluções em tempo oportuno.

<http://www.soft-computing.de/def.html>



## Sistemas de Soft Computing

- Sistemas Fuzzy / Fuzzy Logic
- Redes Neurais Artificiais
- Computação Genética e Evolutiva
- Aprendizagem Máquina / Machine Learning
- Raciocínio Probabilístico






# Redes Neurais Artificiais

## Definição


- Uma **Rede Neuronal Artificial** (RNA) é um sistema computacional de base conexionista para a resolução de problemas.
- Uma RNA é concebida com base num **modelo** simplificado **do sistema nervoso central** dos seres humanos.
- Uma RNA é definida por uma estrutura interligada de unidades computacionais, designadas **neurónios**, com capacidade de **aprendizagem**.



# Redes Neurais Artificiais

## Definição

- Uma **Rede Neuronal Artificial** (RNA) é um sistema computacional de base conexionista para a resolução de problemas.
- Uma RN dos seres vivos.
- Uma RN inspirada no funcionamento do neurón.





# Redes Neurais Artificiais

## Definição

- Uma **Rede Neural Artificial** (RNA) é um sistema computacional de base conexionista para a resolução de
- Uma RNA é concebida para simular a estrutura e a função dos seres humanos
- Uma RNA é definida por um conjunto de **neurónios**, com c

A graphic titled "Biological Simulation" showing a network of glowing blue and orange neurons on a black background. The text "Biological Simulation" is written in large, white, bold letters with a blue outline.

Biological  
Simulation

# Redes Neurais Artificiais

## Neurónio


- **Unidade computacional** de composição da RNA.
- **Identificado** pela sua **posição** na rede.
- Caracterizado pelo **valor do estado**.



# Redes Neurais Artificiais

## Axónio

- **Via de comunicação** entre os neurónios.
- Pode **ligar qualquer neurónio**, incluindo o próprio.
- As ligações podem **variar** ao longo do **tempo**.
- A informação circula em **um só sentido**.






# Redes Neurais Artificiais

## Sinapse

- **Ponto de ligação** entre axónios e neurónios.
- O **valor da sinapse** determina o **peso** (importância) do sinal a entrar no neurónio: excitativo, inibidor ou nulo.
- A **variação no tempo determina a aprendizagem** da RNA.



# Redes Neurais Artificiais

## Ativação

- O valor de ativação é representado por **um único valor**.
- O valor de ativação **varia com o tempo**.
- A gama de valores varia com o modelo adotado (normalmente está dependente das entradas e de algum efeito de memória).



# Redes Neurais Artificiais

## Transferência

- O valor de transferência de um neurónio determina **o valor** que é **colocado na saída** (transferido através do axónio).
- É calculado como uma função do valor de ativação (eventualmente com algum efeito de memória).








# Redes Neurais Artificiais

## Tarefas de um neurónio

- Cálculo do valor de saída (output =  $O_i$ ), função do valor de ativação:

$$O_i = f_T ( A_i )$$



- Cálculo do valor de ativação (  $A_j$  ).
- Varia no tempo com o seu próprio valor e o de outras entradas (  $w_{ij}$  ;  $I$  ):


$$A_j = \mathcal{F}( A_{j-1}; I_j; \sum w_{i,j} \times O_i )$$

- **Aprendizagem:** regras de modificação dos pesos (  $w_i$  ).


# Redes Neurais Artificiais

## Arquiteturas de RNAs


- *Feed forward*, de uma só camada:



- *Feed forward*, multi-camada:




- Recorrente



# Redes Neuronais Artificiais

## Paradigmas de aprendizagem

- Sem supervisão:




(p.ex., quando dois neurónios adjacentes têm variações da ativação no mesmo sentido, então o peso da ligação deve ser progressivamente aumentado.)



# Redes Neuronais Artificiais

## Paradigmas de aprendizagem

- Com supervisão:



(p.ex., os ajustes nos pesos das ligações são efetuados por forma a minimizar o erro produzido pelos resultados da RNA.)

- De reforço: o exemplo contém, apenas, uma indicação sobre a correção do resultado.

# Redes Neurais Artificiais

## Regras de treino (aprendizagem)

- O treino de uma RNA corresponde à aplicação de regras de aprendizagem, por forma a fazer variar os pesos das ligações (sinapses);
- Exemplos de regras de aprendizagem mais comuns são:
  - *Hebbian*;
  - Competitiva;
  - Estocástica;
  - Baseada na memória;
  - Gradiente decrescente.

# Redes Neurais Artificiais

## Especificação

- Quantidade de neurónios:
  - na camada de entrada;
  - na camada de saída;
  - nas camadas intermédias;
- Níveis (ou camadas) da RNA;
- Ligações entre neurónios;
- Topologia das ligações;
- Esquema de atribuição e atualização dos pesos;
- Funções:
  - de transferência;
  - de ativação;
  - de aprendizagem;
- Métodos de Treino.



# Redes Neurais Artificiais


**Resolução de problemas com RNA's**

▪ Problema: XOR

A	B	XOR
0	0	0
0	1	1
1	0	1
1	1	0

▪ Função de ativação:  
 $F_A = \sum \text{entradas} \times \text{pesos}$


▪ Função de transferência:




# Redes Neurais Artificiais

## Resolução de problemas com RNA's

- RNA *feed forward*, completamente ligada, com camadas 2-1;
- Assumir o resultado de treino dado por:




$$F_A = \sum \text{entradas} \times \text{pesos}$$



# Redes Neurais Artificiais


## Resolução de problemas com RNA's

- RNA *feed forward*, completamente ligada, com camadas 2-1;
- Assumir o resultado de treino dado por:



A	B	XOR
0	0	0
0	1	1
1	0	1
1	1	1


$$F_A = \sum \text{entradas} \times \text{pesos}$$




# Redes Neurais Artificiais

**Resolução de problemas com RNA's**

- RNA *feed forward*, completamente ligada, com **camadas 2-2-1**;
- Assumir o resultado de treino dado por:



$$F_A = \sum \text{entradas} \times \text{pesos}$$






# Redes Neurais Artificiais


## Resolução de problemas com RNA's

- RNA *feed forward*, completamente ligada, com **camadas 2-2-1**;
- Assumir o resultado de treino dado por:



A	B	XOR
0	0	0
0	1	1
1	0	1
1	1	0

$$F_A = \sum \text{entradas} \times \text{pesos}$$



# Redes Neurais Artificiais

## Treino de RNA's

- Considere-se uma Rede Neuronal Artificial...

**RNA**

# Redes Neurais Artificiais

## Treino de RNA's


- ... composta por 2 neurónios à entrada e 1 à saída...



# Redes Neurais Artificiais

## Treino de RNA's

- ... *feed forward*, completamente ligada.






# Redes Neurais Artificiais

## Treino de RNA's


- Os exemplos de treino contêm os resultados pretendidos.



# Redes Neurais Artificiais

## Treino de RNA's

- Atribuição aleatória dos pesos às sinapses.




$$f_A(P,E) = \sum P \times E$$

$$f_r(A) = A$$

# Redes Neurais Artificiais

## Treino de RNA's

- Cálculo do valor de ativação...




$$f_A(P, E) = \sum P \times E$$

$$f_r(A) = A$$

# Redes Neurais Artificiais

## Treino de RNA's

- ... para todos os neurónios da camada intermédia.



$$f_A(P,E) = \sum P \times E$$


$$f_r(A) = A$$



# Redes Neurais Artificiais

## Treino de RNA's

- Cálculo do valor de transferência.




$$f_A(P, E) = \sum P \times E$$

$$f_t(A) = A$$

# Redes Neurais Artificiais

## Treino de RNA's

- Valor de ativação na camada de saída...




$$f_A(P, E) = \sum P \times E$$

$$f_r(A) = A$$

# Redes Neurais Artificiais

## Treino de RNA's

- ... e respectivo valor de transferência.




$$f_A(P, E) = \sum P \times E$$

$$f_t(A) = A$$

# Redes Neurais Artificiais

## Treino de RNA's

- Cálculo do erro na camada de saída...



$$\mathcal{E} = OUT_D - OUT_C$$

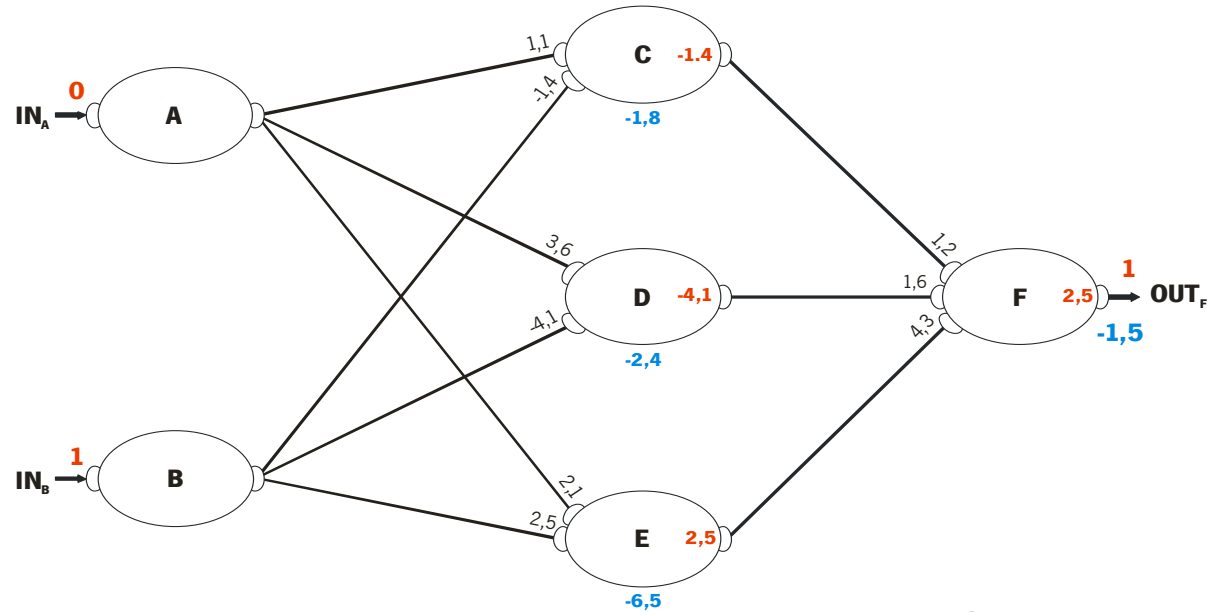
$$\mathcal{E}_{\leftarrow} = \mathcal{E} \times P$$



# Redes Neurais Artificiais

## Treino de RNA's

- ... e cálculo do valor estimado do erro na camada intermédia.



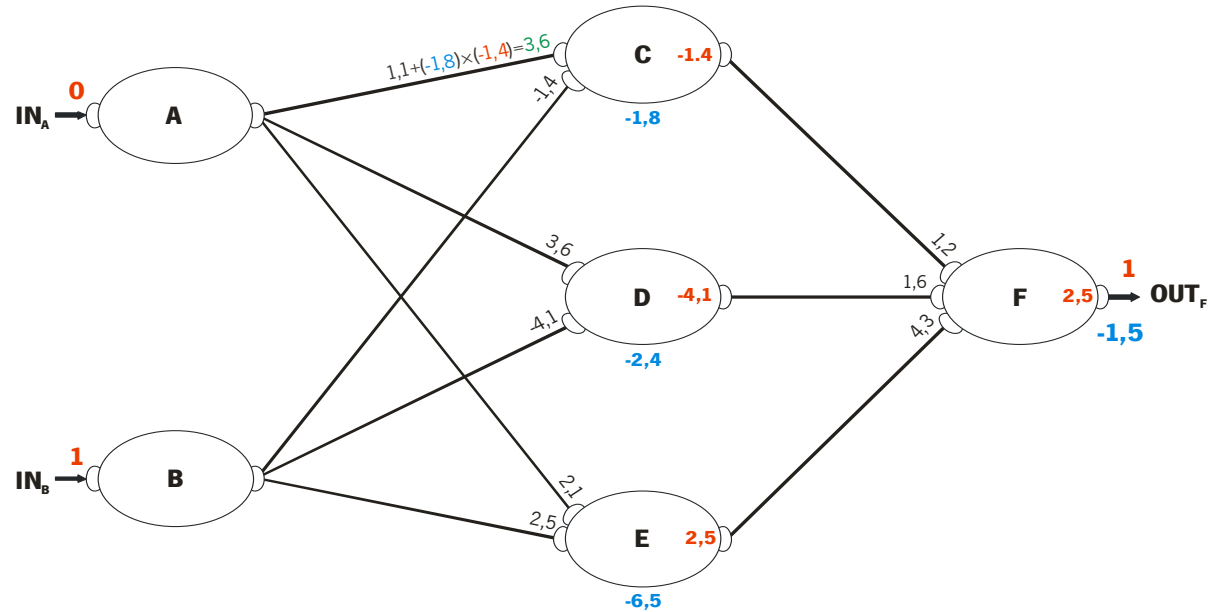
$$\mathcal{E} = OUT_D - OUT_C$$

$$\mathcal{E}_{\leftarrow} = \mathcal{E} \times P$$

# Redes Neurais Artificiais

## Treino de RNA's

- Aplicação de uma regra de atualização dos pesos das sinapses...




$$P_{i+1} = P_i + \epsilon \times f_T$$

# Redes Neurais Artificiais

## Treino de RNA's

- ... para atualizar os valores das sinapses de todos os neurónios.




$$P_{i+1} = P_i + \epsilon \times f_T$$

# Redes Neurais Artificiais

## Treino de RNA's

- Segunda iteração da propagação do caso de treino...



$$f_A(P,E) = \sum P \times E$$


$$f_r(A) = A$$



# Redes Neurais Artificiais

## Treino de RNA's

- ... e cálculo do erro produzido pela RNA na segunda iteração.



# Redes Neurais Artificiais

## Referências bibliográficas

- Cortez, P., Neves, J., “Redes Neurais Artificiais”, Unidade de Ensino, Departamento de Informática, Universidade do Minho, 2000;
- Haykin, S., “Neural Networks – A Comprehensive Foundation”, Prentice-Hall, New Jersey, 2nd Edition, 1999.

### Contactos

- Universidade do Minho
- Escola de Engenharia
- Departamento de Informática
- <http://islab.di.uminho.pt>
- DI-3.22